Visualisation de données avec R

La "Grammar of Graphics"

Robin Cura & Lise Vaudor

15/10/2018

École Thématique GeoViz 2018

Sommaire

La Grammar of Graphics

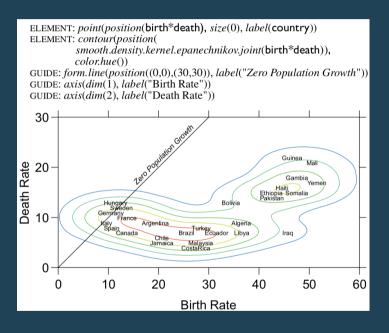
Les composants d'un graphique ggplot2

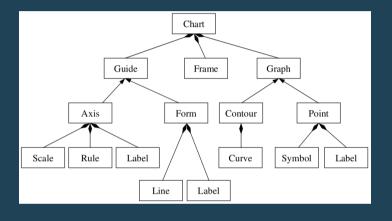
- Des données tidy
- Les géométries : **geom**
- Mapper les variables aux géométries : les aesthetics
- Organiser les échelles : scale_
- Ratios et systèmes de coordonnées : coords
- Les labels d'un graphique
- Définir les légendes : les **guides**
- Décomposer un graphique selon des facets
- Superposition de couches
- Composition d'un planche avec patchwork

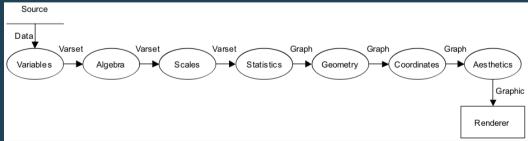
Exercice d'application

Ressources et supports

Conceptualisée par Leland Wilkinson (2006 [1999])

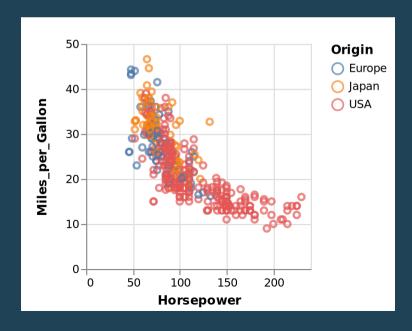






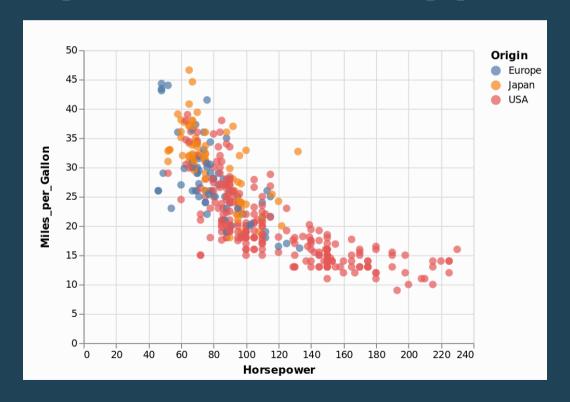
VegaLite (JavaScript)

```
{
    "$schema": "https://vega.github.io/schema/vega-lite/v2.json",
    "data": {"url": "data/cars.json"},
    "mark": "point",
    "encoding": {
        "x": {"field": "Horsepower", "type": "quantitative"},
        "y": {"field": "Miles_per_Gallon", "type": "quantitative"},
        "color": {"field": "Origin", "type": "nominal"}
    }
}
```



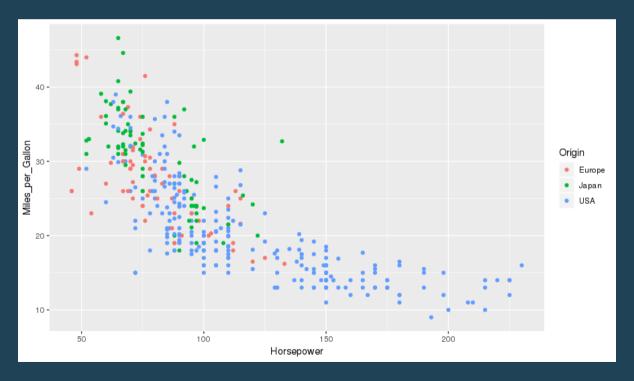
Altair (Python)

```
import altair as alt
alt.Chart(cars).mark_circle(size=60).encode(x='Horsepower', y='Miles_per_Gallon', color='Origin')
```

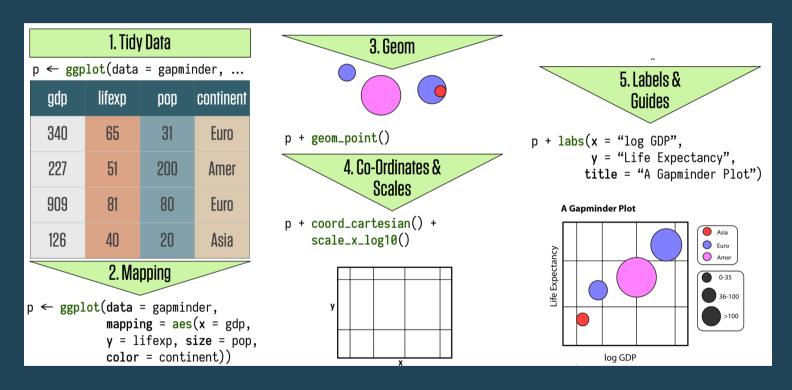


ggplot2 (R)

```
library(ggplot2)
ggplot(cars) +
  geom_point(aes(x = Horsepower, y = Miles_per_Gallon, color = Origin))
```



ggplot2 : une implémentation de la grammar of graphics



Healy, K. (2018). Data Visualization: A Practical Introduction. S.I.: Princeton University Press. http://socviz.co/

ggplot2 : une implémentation de la grammar of graphics

Décrire la syntaxe d'un graphique à l'aide d'une grammaire composée d'éléments atomiques :

- Des données (data)
- Des objets géométriques (point, ligne, rectangle, barre etc.) (geom_*)
 - Un *mapping* entre les données et les "esthétiques" géométriques correspondantes (*aesthetics*, **aes ()**)
- Des échelles pour définir les étendues et transformations de l'espace du graphique (scales_)
- Un système de coordonnées pour définir le lien entre les échelles (coord_)
- Des éléments d'habillage : textes (labels, labs) et légendes (guides, guides)
- Éventuellement, des éléments de décomposition des graphiques, les facets

Tous ces éléments s'accumulent, comme des propriétés supplémentaires, via l'opérateur +

Les données

Tout graphique ggplot2 doit commencer par un appel aux données :

```
library(ggplot2) # ou library(tidyverse)
df_dmr_spatialise <- readRDS(file = "dans_ma_rue_clean.RDS")
ggplot(data = df_dmr_spatialise)</pre>
```

- Les données doivent être structurées de manière tidy, dans un data.frame (ou un tibble):
 - 1 ligne = 1 individu
 - 1 colonne = 1 variable homogène et cohérente
 - Don privilégie des données au format long
- Ex. pour stocker des données temporelles :

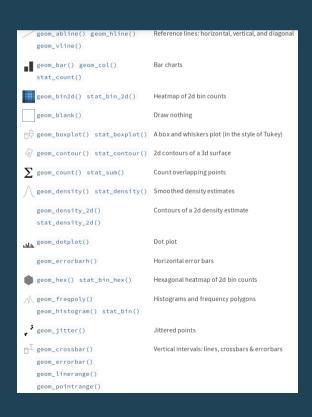
Ville	СР	Pop1999	Pop2011
Paris	75000	2125	2250
Lyon	69000	445	491
Marseille	13000	796	851

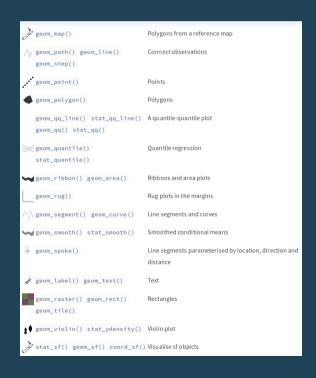
Ville	СР	Annee	Population
Paris	75000	1999	2125
Paris	75000	2011	2250
Lyon	69000	1999	445
Lyon	69000	2011	491
Marseille	13000	1999	796
Marseille	13000	2011	851

Les géométries

• Le composant de base des graphiques : quelle géométrie donner à chaque couche (*layer*) de données ?

https://ggplot2.tidyverse.org/reference/index.html#section-layer-geoms





Les géométries

• Une liste complète dans la cheatsheet de ggplot2



Les aesthetics

- Chaque géométrie comporte des propriétés, génériques (x, y, colour...)
 ou spécifiques (linetype, shape, xmin...) qui doivent être rapportées
 (avec un mapping) à des variables : ce sont les "esthétiques" (aes)
- Ex.: une géométrie de type ponctuelle (**geom_point**) requiert au moins des coordonnées (**x** et **y**), et peut être enrichie avec des propriétés spécifiques (**alpha**, **color**, **fill**, **shape**, **size**, **stroke**):

Les aesthetics

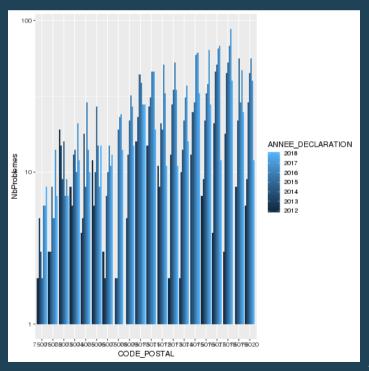
- Chaque géométrie comporte des propriétés, génériques (x, y, colour...)
 ou spécifiques (linetype, shape, xmin...) qui doivent être rapportées
 (avec un mapping) à des variables : ce sont les "esthétiques" (aes)
- Ex.: une géométrie de type ponctuelle (**geom_point**) requiert au moins des coordonnées (**x** et **y**), et peut être enrichie avec des propriétés spécifiques (**alpha**, **color**, **fill**, **shape**, **size**, **stroke**)
- On peut aussi définir des propriétés "globales", qui ne dépendront pas du contenu du jeu de données :

Les aesthetics

- Chaque géométrie comporte des propriétés, génériques (x, y, colour...)
 ou spécifiques (linetype, shape, xmin...) qui doivent être rapportées
 (avec un mapping) à des variables : ce sont les "esthétiques" (aes)
- Ex.: une géométrie de type "colonne" (**geom_col**) requiert au moins des coordonnées (**x** et **y**), et peut être enrichie avec des propriétés spécifiques (**x**, **y**, **alpha**, **color**, **fill**, **group**, **linetype**, **size**, **position**)

Les échelles

- Quand on veut modifier la manière dont les axes sont conçus, on peut jouer sur les échelles (scale_)
- Par exemple, pour choisir une échelle logarithmique pour les ordonnées du graphique précédent :



Les échelles

- Quand on veut modifier la manière dont les axes sont conçus, on peut jouer sur les échelles (scale_)
- Par exemple, pour choisir une échelle logarithmique pour les ordonnées du graphique précédent
- Et pour modifier l'échelle de couleurs :

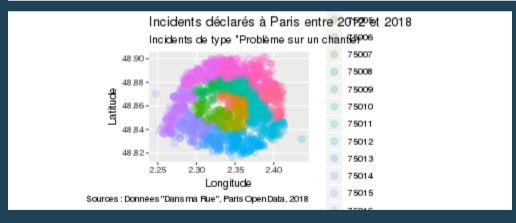
Les coordonnées

 On l'a vu avec les "cartes" de répartition, ggplot2 affiche un graphique en maximisant l'espace disponible pour chaque axe : quand les rapports entre les coordonnées x et y ont un sens, il faut l'expliciter avec les coord_:

Habillage: textes

- Par défaut, les textes (titres des axes etc.) prennent comme valeur automatique le nom des variables qui leurs sont attribuées.
- On peut modifier tous ces éléments, afin d'habiller correctement les graphiques produits, avec l'instruction **labs** (*labels*) :

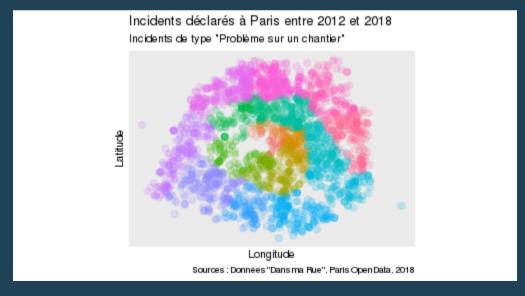
```
ggplot(pointData) +
  geom_point(aes(x = Long, y = Lat, color = CODE_POSTAL), size = 3, alpha = .2) +
  coord_map(projection = "mercator") +
  labs(title = 'Incidents déclarés à Paris entre 2012 et 2018',
    subtitle = 'Incidents de type "Problème sur un chantier"',
    caption = 'Sources : Données "Dans ma Rue", Paris OpenData, 2018',
    x = "Longitude", y = "Latitude")
```



Habillage : légendes

• On peut modifier et désactiver les légendes directement depuis les échelles (scales) correspondantes.

```
ggplot(pointData) +
  geom_point(aes(x = Long, y = Lat, color = CODE_POSTAL), size = 3, alpha = .2) +
  coord_map(projection = "mercator") +
  labs(title = 'Incidents déclarés à Paris entre 2012 et 2018',
    subtitle = 'Incidents de type "Problème sur un chantier"',
    caption = 'Sources : Données "Dans ma Rue", Paris OpenData, 2018',
    x = "Longitude", y = "Latitude") +
  scale_color_discrete(guide = FALSE) +
  scale_x_continuous(labels = NULL, breaks = NULL, minor_breaks = NULL) +
  scale_y_continuous(labels = NULL, breaks = NULL, minor_breaks = NULL)
```



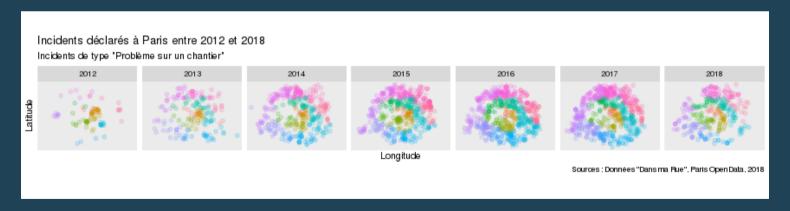
On peut "décomposer" un graphique (en *small multiples*) avec les instructions **facet** :

 facet_wrap (~VARIABLE): décompose le graphique en autant de modalités que contenues dans VARIABLE. On règle leur agencement avec les arguments nrow (nombre de lignes) et/ou ncol (nombre de colonnes).

```
ggplot(pointData) +
  geom_point(aes(x = Long, y = Lat, color = CODE_POSTAL), size = 2, alpha = .2) +
  coord_map(projection = "mercator") +
  labs(title = 'Incidents déclarés à Paris entre 2012 et 2018',
      subtitle = 'Incidents de type "Problème sur un chantier"',
      caption = 'Sources : Données "Dans ma Rue", Paris OpenData, 2018',
      x = "Longitude", y = "Latitude") +
      scale_color_discrete(guide = FALSE) +
      scale_x_continuous(labels = NULL, breaks = NULL, minor_breaks = NULL) +
      scale_y_continuous(labels = NULL, breaks = NULL, minor_breaks = NULL) +
      facet_wrap(~ANNEE_DECLARATION, nrow = 1)
```

On peut "décomposer" un graphique (en *small multiples*) avec les instructions **facet** :

 facet_wrap(~VARIABLE): décompose le graphique en autant de modalités que contenues dans VARIABLE. On règle leur agencement avec les arguments nrow (nombre de lignes) et/ou ncol (nombre de colonnes).



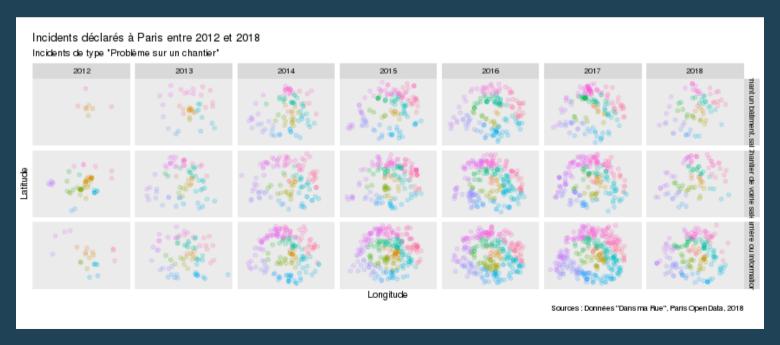
On peut "décomposer" un graphique (en *small multiples*) avec les instructions **facet** :

• facet_grid(VARIABLE1~VARIABLE2): décompose le graphique en un croisement des modalités contenues dans VARIABLE1 et VARIABLE2.

```
ggplot(pointData %>% filter(!is.na(SOUSTYPE))) +
  geom_point(aes(x = Long, y = Lat, color = CODE_POSTAL), size = 2, alpha = .2) +
  coord_map(projection = "mercator") +
  labs(title = 'Incidents déclarés à Paris entre 2012 et 2018',
      subtitle = 'Incidents de type "Problème sur un chantier"',
      caption = 'Sources : Données "Dans ma Rue", Paris OpenData, 2018',
      x = "Longitude", y = "Latitude") +
      scale_color_discrete(guide = FALSE) +
      scale_x_continuous(labels = NULL, breaks = NULL, minor_breaks = NULL) +
      scale_y_continuous(labels = NULL, breaks = NULL, minor_breaks = NULL) +
      facet_grid(SOUSTYPE~ANNEE_DECLARATION)
```

On peut "décomposer" un graphique (en *small multiples*) avec les instructions **facet**_:

• facet_grid(VARIABLE1~VARIABLE2): décompose le graphique en un croisement des modalités contenues dans VARIABLE1 et VARIABLE2.



Superposer des couches graphiques

ggplot2 permet d'empiler des couches de représentations portant sur les mêmes données (représentations différentes) ou sur d'autres jeux de données (si tant est qu'ils se situent dans les mêmes étendues graphiques). Comme pour tous les éléments de ggplot, cela se fait avec l'opérateur + :

```
maCarte <- ggplot(pointData) +
  geom_point(aes(x = Long, y = Lat)) +
  coord_map(projection = "mercator")
maCarte</pre>
```

```
maCarte +
  geom_density2d(aes(x = Long, y = Lat))
```

Superposer des couches graphiques

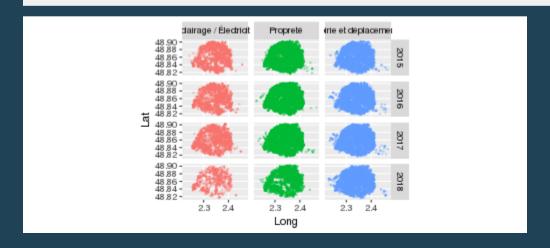
• N.B.: l'ordre d'ajout des couches est important : les dernières couches ajoutées seront positionnées "au dessus" des couches précédentes :

 Avec le package patchwork, on peut facilement agencer différents graphiques

```
library(patchwork) # devtools::install_github("thomasp85/patchwork")

carteData <- df_dmr_spatialise %>%
    filter(TYPE %in% C("Propreté", "Voirie et déplacements", "Éclairage / Électricité")) %>%
    filter(ANNEE_DECLARATION >= 2015) %>%
    mutate(TRIMESTRE = paste(ANNEE_DECLARATION, TRIMESTRE_DECLARATION, sep="-")) %>%
    arrange(TRIMESTRE, TYPE)

maCarte <- ggplot(carteData) +
    geom_point(aes(Long, Lat, colour = TYPE), size = .5, alpha = .3) +
    facet_grid(ANNEE_DECLARATION~TYPE) +
    coord_map(projection = "mercator") +
    scale_colour_discrete(guide = FALSE)</pre>
```

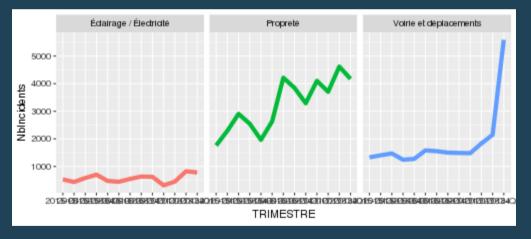


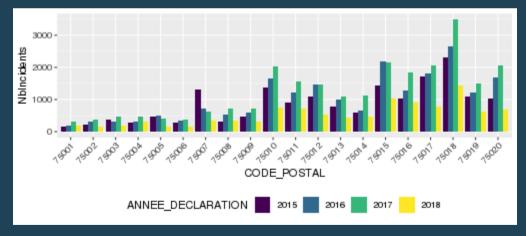
maCarte

```
evolData <- carteData %>%
  group_by(TRIMESTRE, TYPE) %>%
  summarise(NbIncidents = n())

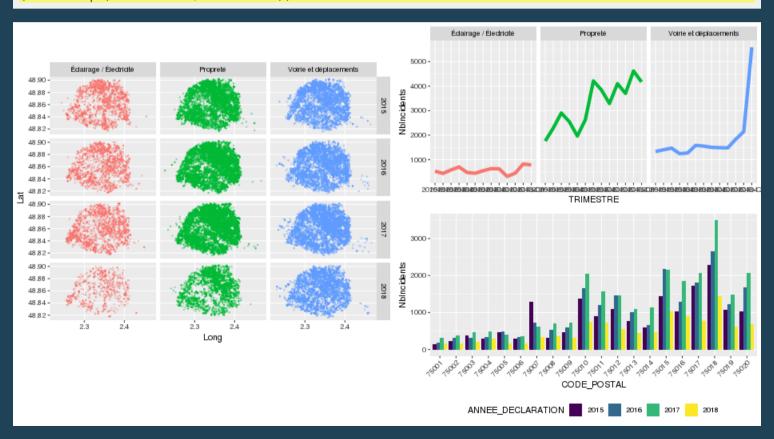
evolNombre <- ggplot(evolData) +
  geom_line(aes(TRIMESTRE, NbIncidents, colour = TYPE, group = TYPE), size = 2) +
  facet_wrap(~TYPE, nrow = 1) +
  scale_colour_discrete(guide = FALSE)

evolNombre</pre>
```





(maCarte | (evolNombre / evolArrdt))



Cheatsheets

Data Visualization with ggplot? · · CUEAT SUEET





www.rstudio.com/resources/cheatsheets/#ggplot2

Où trouver de la documentation/aide ?

- Articles rstudio
- Blogs? Lesquels?
- Livres

Un peu de pratique!
Proposer des représentations graphiques, à partir du jeu de données "Dans ma Rue", permettant de saisir l'évolution, dans le temps et dans l'espace, des signalements d'anomalies.